Predicción de la Severidad de Accidentes de Tránsito Mediante Aprendizaje Automático Supervisado

Jose Muñoz Ríos y Santiago Álvarez Peña
Ingeniería de Sistemas, Universidad EAFIT — Machine Learning Applied
Colombia

I. INTRODUCCIÓN

A. Contexto y motivación

Los siniestros viales causan cerca de 1.19 millones de muertes al año y son la principal causa de muerte entre personas de 5 a 29 años; nueve de cada diez de esas muertes ocurren en países de ingresos bajos y medios [1]. En esos contextos, el tráfico mixto y los recursos limitados para atender emergencias hacen especialmente valioso anticipar qué siniestros tendrán consecuencias graves.

El análisis tradicional de accidentalidad, basado en estadística descriptiva, capta mal las relaciones no lineales entre los factores del conductor, el vehículo, la vía y el entorno. El aprendizaje automático se ha propuesto como complemento para estimar la severidad de un siniestro a partir de las condiciones en que ocurre [2]. Este trabajo aplica ese enfoque a un conjunto de datos público de Addis Abeba, Etiopía [3], una ciudad con retos de seguridad vial comparables a los de muchas ciudades latinoamericanas.

B. Planteamiento del problema

Hoy, la priorización de recursos de emergencia y de intervenciones viales se basa en registros agregados y en la experiencia de los organismos de tránsito, sin un mecanismo que relacione las características de cada siniestro con su severidad esperada. El resultado son recursos mal priorizados y políticas poco sustentadas en evidencia. Una solución beneficiaría a las autoridades de tránsito y a los organismos de salud y, de forma indirecta, a conductores y peatones.

El problema es abordable con los datos disponibles: 12,316 registros con 22 variables predictoras tras la depuración y una etiqueta de severidad (leve, grave o fatal), lo que permite plantearlo como una clasificación supervisada multiclase. El documento se organiza así: la Sección II resume trabajos previos; la Sección III plantea la pregunta de investigación; las Secciones IV y V describen los datos y los hallazgos del análisis exploratorio, en especial el fuerte desbalance de clases; la Sección VI detalla la metodología de entrenamiento y validación; la Sección VII presenta los resultados de tres modelos frente a una línea base; la Sección VIII discute su alcance y sus limitaciones, y la Sección IX concluye. En síntesis, el mejor modelo supera a la línea base, pero de forma modesta y sin detectar los casos fatales.

II. TRABAJOS RELACIONADOS

El conjunto de Addis Abeba fue publicado por Bedane [3], quien lo usó en un estudio sobre prevención de accidentes con modelos predictivos [4]. Endalie y Abebe [5] aplicaron sobre él reglas de asociación (Apriori), que identificaron combinaciones de factores frecuentes en accidentes de alta severidad, y un clasificador SVM con 85% de exactitud, superior a K-vecinos, árboles de decisión y Random Forest. En el Reino Unido, Obasi y Benson [2] compararon cuatro algoritmos sobre 2,047,256 registros (2005–2014) y alcanzaron 87% de exactitud con Random Forest y Regresión Logística; la capacidad del motor, la edad del vehículo y la del conductor estuvieron entre las variables más influyentes.

Los estudios [2] y [5] reportan principalmente exactitud global, pero en este dataset predecir siempre «leve» ya da 84.6%. La oportunidad es evaluar con métricas sensibles al desbalance y con una validación que respete la estructura de los datos, en la que varias filas pueden pertenecer al mismo siniestro.

III. PREGUNTA DE INVESTIGACIÓN

¿Es posible predecir la severidad de un accidente de tránsito (leve, grave o fatal) a partir de las características del conductor, el vehículo, la vía y el entorno registradas en el siniestro, con un F1-macro superior al de un clasificador trivial? Es un problema de aprendizaje supervisado de clasificación multiclase, con Accident_severity como variable objetivo.

IV. CARACTERIZACIÓN DE LOS DATOS

Se usa el Road Traffic Accident Dataset of Addis Ababa City [3], construido con registros policiales de 2017 a 2020: 12,316 registros y 32 columnas (31 predictoras y la variable objetivo). Cada fila corresponde a un conductor o vehículo involucrado, no a un accidente: al agrupar por hora, día y condiciones del evento se obtienen unos 5,272 siniestros, con 2.34 registros en promedio.

En la depuración se eliminaron las cuatro columnas con más de 20% de nulos (p. ej., Defect_of_vehicle, con 35.9%) y cinco variables de la víctima o posteriores al accidente (p. ej., Casualty_severity), que filtrarían información del desenlace. Time se transformó en la hora del día, y los nulos restantes (7.7% como máximo por columna) se codificaron como «Unknown». El resultado tiene 22 predictoras sin nulos ni duplicados (Tabla I): 20 categóricas y 2 numéricas (hora y número de vehículos).

TABLA I

Variables Predictoras del Dataset Depurado

Categoría	Variables (columnas)
Conductor (5)	Age_band_of_driver, Sex_of_driver, Educational_level, Driving_experience, Vehicle_driver_relation
Vehículo (3)	Type_of_vehicle, Owner_of_vehicle, Vehicle_movement
Vía (6)	Area_accident_occured, Lanes_or_Medians, Road_allignment, Types_of_Junction, Road_surface_type, Road_surface_conditions
Entorno / evento (8)	Hour, Day_of_week, Light_conditions, Weather_conditions, Type_of_collision, Number_of_vehicles_involved, Pedestrian_movement, Cause_of_accident

La variable objetivo es Accident_severity, categórica con tres clases: Slight Injury (leve), Serious Injury (grave) y Fatal injury (fatal).

V. INSIGHTS PRELIMINARES (EDA)

El hallazgo central es el fuerte desbalance de clases (Tabla II y Fig. 1(a)): 84.6% de los registros son leves, 14.2% graves y solo 1.3% fatales, es decir, hay 66 leves por cada fatal. Un clasificador que siempre predice «leve» obtiene 84.6% de exactitud, pero un F1-macro de 0.31, porque no detecta ningún caso grave ni fatal. Por eso los modelos se evaluaron con F1-macro y recall por clase, y se entrenaron con pesos por clase (Sección VI).

TABLA II

Distribución de la Variable Objetivo (Accident_severity)

Clase	N° registros	% del total
Slight Injury	10,415	84.6%
Serious Injury	1,743	14.2%
Fatal injury	158	1.3%

Las demás variables tienen asociaciones débiles con la severidad (V de Cramér ≤ 0.11; solo 8 de las 22 son significativas). La más fuerte es el número de vehículos: los siniestros de un solo vehículo terminan en lesión grave o fatal en el 28.2% de los casos, frente al 12.8% de los de dos vehículos (Fig. 1(b)). El análisis completo, que incluye la iluminación y la hora, está en el notebook de EDA.

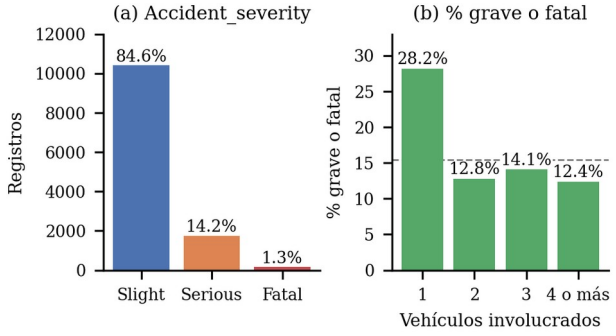


Fig. 1. (a) Distribución de la variable objetivo. (b) Porcentaje de lesiones graves o fatales según el número de vehículos; la línea punteada es el promedio general.

VI. METODOLOGÍA

A. Partición y validación

Como varias filas pertenecen al mismo siniestro, una partición aleatoria pondría registros de un mismo evento en entrenamiento y en prueba. Por eso se construyó un identificador aproximado de siniestro (hora, día, número de vehículos y de víctimas, iluminación, clima y estado de la vía) y se usó una partición estratificada por grupos: el 20% de los siniestros (1,063 siniestros, 2,463 registros, 32 fatales) se reservó como conjunto de prueba, sin eventos compartidos con el entrenamiento. Con el 80% restante (4,209 siniestros, 9,853 registros) se ajustaron los hiperparámetros mediante validación cruzada de 5 folds, también por grupos y estratificada.

B. Preprocesamiento y modelos

Todo el preprocesamiento se ajustó dentro de cada fold con un pipeline: one-hot para las 20 variables categóricas (agrupando las categorías con menos del 1% de los registros), codificación cíclica de la hora (seno y coseno) y estandarización del número de vehículos, para un total de 141 columnas. Se compararon una línea base que predice la clase mayoritaria, Regresión Logística (modelo lineal de referencia), Random Forest e Histogram Gradient Boosting (en adelante, Gradient Boosting), modelos de árboles que capturan interacciones. Para el desbalance se usaron pesos por clase en la función de pérdida, sin generar registros sintéticos: pesos inversos a la frecuencia (66 : 6 : 1 para fatal, grave y leve) o su raíz cuadrada (8.1 : 2.4 : 1), tratados como un hiperparámetro más. Se prefirieron los pesos al sobremuestreo con SMOTE porque este interpola registros en un espacio numérico y no es adecuado para variables casi todas categóricas.

C. Selección y métricas

Cada modelo se ajustó con una búsqueda aleatoria de 12 combinaciones que maximiza el F1-macro en validación cruzada. Se exploraron la regularización de la Regresión Logística; la profundidad, el tamaño mínimo de hoja y la fracción de variables de Random Forest (300 árboles), y la tasa de aprendizaje, la profundidad, el número de hojas y la regularización de Gradient Boosting (300 iteraciones). Se eligió el F1-macro porque da el mismo peso a las tres clases, a diferencia de la exactitud. El modelo final se eligió por su F1-macro medio en validación, sin usar el conjunto de prueba; después, cada modelo se evaluó una sola vez en prueba. También se reportan la exactitud balanceada, el recall por clase y el AUC macro.

D. Entrenamientos no válidos

Como contraste se reprodujeron dos errores comunes, con los mismos hiperparámetros: (i) una validación cruzada aleatoria, que ignora los grupos y permite que el modelo vea en entrenamiento registros del mismo siniestro que luego evalúa (fuga de información), y (ii) un entrenamiento sin pesos por clase, que en la práctica optimiza la exactitud.

E. Implementación

Los experimentos se implementaron en Python con pandas y scikit-learn, con una semilla fija para que las particiones y los modelos sean reproducibles. El EDA y el modelado están en dos notebooks (data_s5_eda.ipynb y modelado.ipynb), que generan todas las cifras, tablas y figuras de las Secciones IV a VII.

VII. RESULTADOS

La Tabla III resume los resultados. Los tres modelos superan a la línea base en F1-macro, tanto en validación cruzada como en prueba. Random Forest obtuvo el mejor F1-macro en validación (0.38 ± 0.02), con profundidad máxima de 10, al menos 10 registros por hoja, 20% de las variables en cada división y pesos balanceados, y se seleccionó como modelo final. En prueba alcanzó un F1-macro de 0.37, frente a 0.31 de la línea base, y una exactitud balanceada de 0.38, frente a 0.33, aunque su AUC macro (0.53; 0.46 en la clase fatal) indica que ordena los registros por riesgo casi igual que el azar. Su mejora se concentra en la clase grave (recall de 0.30), aunque con una precisión de solo 0.23 en esa clase; en cambio, su recall en la clase fatal fue de 0.00, y el 81% de los casos fatales se clasificó como leve (Fig. 2(a)). La Regresión Logística casi siempre predice «leve» (recall grave de 0.06), y Gradient Boosting detecta algo más de casos graves (0.34) a costa de más falsas alarmas. La exactitud de los modelos (0.70–0.83) es menor que la de la línea base (0.85).

TABLA III

Resultados en Validación Cruzada (CV) y en Prueba

Modelo	F1-m CV	F1-m	Rec. F	Rec. G	Rec. L
Línea base	0.31	0.31	0.00	0.00	1.00
Reg. Logística	0.35	0.35	0.03	0.06	0.98
Random Forest	0.38	0.37	0.00	0.30	0.83
Grad. Boosting	0.37	0.35	0.00	0.34	0.77

F1-m: F1-macro. Rec. F/G/L: recall de las clases fatal, grave y leve.

Los entrenamientos no válidos confirman los riesgos metodológicos (Tabla IV). La validación aleatoria sobreestimó el F1-macro de los modelos de árboles en 6 a 8 puntos (Fig. 2(b)), mientras que la Regresión Logística, menos flexible, no se vio afectada. Sin pesos por clase, la Regresión Logística y Random Forest predijeron «leve» para todos los registros de prueba: su exactitud igualó a la de la línea base, pero su F1-macro no la superó; Gradient Boosting sin pesos detectó apenas el 5% de los casos graves.

TABLA IV

F1-macro con Entrenamientos Válidos y No Válidos

Modelo	CV grupos	CV aleat.†	Prueba	Sin pesos†
Reg. Logística	0.35	0.34	0.35	0.31
Random Forest	0.38	0.44	0.37	0.31
Grad. Boosting	0.37	0.45	0.35	0.33

† Entrenamientos no válidos. «Sin pesos»: F1-macro en prueba sin pesos por clase. Línea base: 0.31.

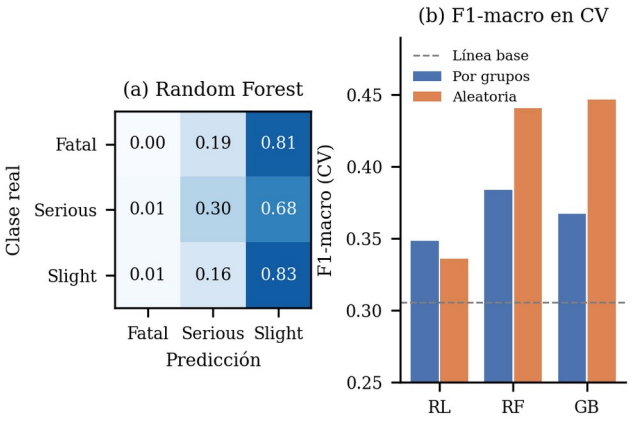


Fig. 2. (a) Matriz de confusión de Random Forest en prueba, normalizada por clase real. (b) F1-macro en validación cruzada por grupos y aleatoria; la línea punteada es la línea base.

VIII. DISCUSIÓN

La respuesta a la pregunta de investigación es afirmativa, pero limitada: las variables registradas permiten superar al clasificador trivial, sobre todo para identificar lesiones graves, pero la ganancia es modesta, la capacidad de ordenar por riesgo es baja y no alcanza para detectar los casos fatales, que son los de mayor interés para priorizar emergencias. Esto es coherente con el EDA, que mostró asociaciones individuales débiles, y con la escasez de ejemplos fatales (126 en entrenamiento y 32 en prueba), que además hace muy inestable su recall.

Los resultados también matizan la literatura: el 85% de exactitud reportado sobre este dataset [5] es similar al de la línea base, así que por sí solo no demuestra capacidad para detectar casos graves; por eso aquí se priorizó el F1-macro, aun a costa de una menor exactitud. Además, la diferencia entre la validación aleatoria y la validación por grupos muestra que ignorar la estructura de los datos produce resultados optimistas. Frente a estudios con millones de registros [2], el tamaño de este conjunto, y en especial el número de casos fatales, limita lo que un modelo puede aprender.

En términos prácticos, el modelo aún no sirve para despachar recursos: con una precisión de 0.23 en la clase grave, la mayoría de sus alertas serían falsas, y no ofrece alertas útiles para los casos fatales. La ventaja de los modelos de árboles sobre la Regresión Logística sugiere que las interacciones entre variables aportan algo de señal, aunque la diferencia entre Random Forest y Gradient Boosting (0.02) es comparable a la variación entre folds.

Las principales limitaciones son el identificador de siniestro aproximado, la posible inconsistencia de la etiqueta dentro de un mismo evento, las numerosas categorías «Unknown» o poco frecuentes y el origen de los datos en una sola ciudad. Como trabajo futuro se propone ajustar los umbrales de decisión según el costo de cada error, reformular el problema como binario (grave o fatal frente a leve), probar sobremuestreo adaptado a variables categóricas (p. ej., SMOTE-NC) y analizar la importancia de las variables.

IX. CONCLUSIONES

Este trabajo evaluó la clasificación de la severidad de accidentes de tránsito en Addis Abeba con una metodología que respeta la estructura de los datos, y deja tres conclusiones. Primero, el desbalance de clases vuelve engañosa la exactitud: un clasificador trivial obtiene 84.6%. Segundo, con validación por siniestros y pesos por clase, Random Forest alcanzó un F1-macro de 0.37, superior al de la línea base (0.31), gracias sobre todo a la detección de lesiones graves, aunque sin identificar los casos fatales. Tercero, validar de forma aleatoria o entrenar sin ponderar las clases habría llevado a conclusiones erróneas. Las variables disponibles contienen señal útil pero limitada; para apoyar decisiones de emergencia se necesitarían más casos fatales o variables adicionales sobre el evento.

REFERENCIAS

[1] World Health Organization, *Global Status Report on Road Safety 2023*. Geneva, Switzerland: WHO, 2023.

[2] I. C. Obasi and C. Benson, "Evaluating the effectiveness of machine learning techniques in forecasting the severity of traffic accidents," *Heliyon*, vol. 9, no. 8, Art. no. e18812, 2023, doi: 10.1016/j.heliyon.2023.e18812.

[3] T. T. Bedane, "Road Traffic Accident Dataset of Addis Ababa City," Mendeley Data, V1, 2020, doi: 10.17632/xytv86278f.1.

[4] T. T. Bedane, B. G. Assefa, and S. K. Mohapatra, "Preventing traffic accidents through machine learning predictive models," in *Proc. Int. Conf. Inf. Commun. Technol. Develop. Africa (ICT4DA)*, Bahir Dar, Ethiopia, 2021, pp. 36–41.

[5] D. Endalie and W. T. Abebe, "Analysis and detection of road traffic accident severity via data mining techniques: Case study Addis Ababa, Ethiopia," *Math. Probl. Eng.*, vol. 2023, Art. no. 6536768, 2023, doi: 10.1155/2023/6536768.